

6. INTRODUCCION A MACHINE LEARNING

José J. Martínez P.

Jmcursosingenieria111@gmail.com

Septiembre 2026

6.1 Introducción

Machine Learning, ML, es un término que ya se venía utilizando desde el siglo pasado. Aunque, su florecimiento no es muy viejo, solo se logró hasta 2005, cuando G. Hinton, uno de los ganadores del Premio Nobel de Física 2024, publicó un artículo en el que mostraba cómo al entrenar una red neuronal profunda, se podían reconocer dígitos escritos a mano, con una precisión del 98%. Como se ha mencionado, la historia de las redes neuronales ha sido una historia de amores y desamores y a finales de los 90s se había abandonado su investigación en estas redes. Con este artículo se demostró que con Deep Learning era posible lograr cosas que ninguna otra técnica de ML había hecho. El entusiasmo se extendió a muchas otras áreas de aplicación y digamos que ahora estamos viviendo el auge de ML, que, considero, va a durar bastante tiempo.

Sin embargo, hay otras técnicas básicas diferentes a las RNAs, para enfrentar los mismos y otros problemas, especialmente Bayes simple, K-NN Nearest, SVM (Support Vector Machine) y árboles de decisión, que consideramos son importantes de mencionar dentro de la gama de herramientas de IA. Estas últimas las presentamos en un apéndice.

Supongamos el siguiente problema: traducir un texto escrito en un idioma a otro y solucionarlo con las técnicas actuales de programación. Para hacer un programa de computador que realice esta tarea, inicialmente, hay que estudiar la gramática de ambos lenguajes, con el fin de codificar sus reglas; algo que no es tan simple. Luego se deben incluir los diccionarios de ambos lenguajes, incluir también la codificación de las búsquedas y seleccionar las palabras más apropiadas en el lenguaje de destino; otra tarea de programación complicada.

Pero hay más, ¿cómo trabajar con palabras homógrafas u homónimas? Por ejemplo, la palabra “can” en inglés, traducida al español puede ser el verbo poder o puede ser simplemente una lata. ***Todo depende del contexto***, una frase con la que nos volveremos a encontrar. ¿Pero cómo codificamos apropiadamente ese contexto? La solución de este tipo de problemas, bajo este concepto de programación, es extremadamente difícil y por esto los traductores de lenguajes, antes de ML eran muy pobres.

Ahora las cosas han cambiado. Se encontró que la solución de muchos problemas complejos se encuentra en los datos. Utilizando una gran cantidad de datos provenientes de diferentes fuentes de la web, Google tiene un modelo de traductor pre-entrenado que va mejorando sus resultados, de manera tan sorprendente, que en algunos casos supera el nivel de un traductor humano.

Con base en este punto de vista, ahora se han desarrollado cientos de aplicaciones, que silenciosamente le dan poder a cientos de productos que usamos regularmente; desde mejores

recomendaciones hasta búsquedas por voz. Es por esto que, nos pueden surgir algunas preguntas:

- ¿Qué es ML?
- ¿Por qué el uso de ML?
- ¿Cómo aprende ML?

6.2 las respuestas

Veamos varias definiciones de ML:

- “ML es el campo de estudio que le da a los computadores la habilidad para aprender sin que sean explícitamente programados”. Arthur Samuel 1959.
- “ML es la ciencia o el arte de programar los computadores, de manera que aprendan a partir de los datos”.
- Una simple: “Sistemas que mejoran su comportamiento con respecto a una tarea con más y más experiencia o datos”
- Más orientada a la ingeniería: “Se dice que un programa de computador aprende de la experiencia **E**, con respecto a una tarea **T**, con una medida de comportamiento **P**, si su comportamiento sobre **T**, medido por **P**, mejora con la experiencia”. Tom Mitchel 1998.

Otra forma de ver ML. En la figura 6.1, se puede observar, ML en comparación con la programación tradicional tomando como ejemplo encontrar la raíz cuadrada de un número.

Veamos un caso de programación tradicional: programar la solución de un problema matemático utilizando el método de Newton, por ejemplo calcular la raíz cuadrada de un número. En el caso de ML, tendríamos miles de ejemplos con resultados correctos de la raíz cuadrada y a través de regresión podríamos encontrar el modelo que me permite calcular cualquier raíz cuadrada, y para un caso concreto encontrar la solución.





Figura 6.1. Programación tradicional versus ML.

Para mayor claridad, vamos a trabajar un ejemplo que es el filtro que tienen los sistemas de correo electrónico para detectar correos engañosos, que se conocen como SPAM. El filtro spam que usa nuestro correo, es un programa de ML, que, con base en instancias de emails rotuladas como spam, observa qué mensajes del correo marca o no como spam; y con qué instancias de correos normales, aprende a cómo filtrar mejor el spam. Esas instancias de emails que usa el sistema para aprender se llaman el conjunto de entrenamiento, o dataset.

Volviendo a la última definición de ML, la tarea **T** del filtro Spam es rotular los correos que llegan como spam, correo no deseado, cuando esos correos presentan ciertas características (features) que el filtro Spam tiene clasificadas como comunes a todos los correos spam. La experiencia **E**, es el conjunto de correos buenos y malos, es el data set que tiene el sistema y del cual aprende. Este data set, Google lo ha ido recabando de la interacción permanente con sus usuarios en todo el mundo. Mientras que **P** es la predicción que hace el sistema de si un determinado correo es spam o no; también se conoce como el comportamiento del sistema, que depende de qué tan bien hace la predicción y se le asigna una precisión. Para esto se usa la Matriz de Confusión, figura 6.2, que se usa mucho en problemas de clasificación

Matriz de Confusión		Predice	
		Positivo	Negativo
Real	Positivo	VP	FN
	Negativo	FP	VN

VP: Verdadero Positivo

FN: Falso Negativo

FP: Falso Positivo

VN: Verdadero Negativo

$$Precisión = \frac{VP + VN}{VP + VN + FP + FN}$$

Figura 6.2. Matriz de Confusión, permite encontrar la precisión de un sistema de clasificación por ML.

6.3 Porque el uso de ML

Volvamos a nuestro ejemplo del filtro Spam. Digamos que vamos a escribir el programa del sistema clasificador, el filtro spam, usando técnicas de programación tradicional. Siguiendo unos pasos básicos de Ingeniería de Software, primero debemos enterarnos cómo son los correos no deseados, cómo es la forma de los encabezados, la del tema y la del contenido. Aparecen palabras como “gratis”, “regalo”, “tarjeta de crédito”, etcétera.

Con base en toda esta información se encuentran estas palabras y algunos patrones que casi siempre se presentan en los correos spam. De manera que como la solución tradicional se entra a programar el filtro; para que cada una de estas palabras y patrones, permitan que el programa detecte los correos no deseados.

Con un gran esfuerzo de programación, puede ser que se llegue a que ese filtro Spam funcione correctamente. Pero solo lo va a hacer durante un determinado tiempo, pues los que producen los correos Spam se dan cuenta y van a buscar otras palabras y otros patrones, para burlar el filtro programado. Ahora, el filtro que se programó deja de funcionar un tiempo, hasta cuando, los desarrolladores del filtro programado se den cuenta de que su sistema está dejando pasar correos spam.




Figura 6.3 Construcción del filtro spam con el enfoque de programación tradicional

Ahora las nuevas palabras pueden ser “pandemia”, “soledad”, “ayuda”, “anticovid”. Entonces, después de haber logrado esta tarea, con su correspondiente gasto de tiempo, en el programa se deben incluir estas nuevas palabras y encabezados; otro gran esfuerzo. Pero nuevamente quienes producen los spam buscan nuevas formas de que sus correos sean aceptados como correos buenos. De manera que después de un análisis, se tendrá que volver a actualizar el programa del filtro; y así sucesivamente. Entonces llegamos a la conclusión de que definitivamente esta no es la mejor manera de mantener un filtro actualizado y funcionando permanentemente.

6.4 Cómo aprende ML

En contraste, un filtro de spam basado en técnicas ML, aprende automáticamente qué palabras y frases son buenos predictores, las características, de spam, detectando patrones inusualmente frecuentes de las palabras en los correos spam, comparados con los ejemplos normales. El programa es mucho más corto, más fácil de mantener y probablemente más preciso. Por lo que un filtro spam basado en ML se dará cuenta automáticamente que “pandemia”, “soledad”, “ayuda”, “anticovid”; se han vuelto inusualmente frecuentes en los emails rotulados por los usuarios como spam y comenzará a marcarlos sin necesidad de reprogramarlo.




Figura 6.4. Enfoque de programación con ML.

En la figura 6.4, se puede observar cómo funciona la programación ML. El primer paso, lo mismo que en la programación tradicional se estudia el problema, pero luego se cambia, se consigue el data set de spams y hams y se entrena un algoritmo de ML, que es realmente un **modelo**. Se evalúa su solución hasta cuando el modelo funcione bien y se lanza a producción. Sin embargo, en la medida en que los spams van cambiando, los usuarios van rotulando qué correos son no deseados, el modelo va aprendiendo y se va ajustando permanentemente a las nuevas formas de spam. Así, la actualización del filtro es automática.

Aplicar las técnicas de ML para explorar en grandes cantidades de datos, puede ayudar a descubrir patrones que no eran evidentes, lo que se conoce como “*minería de datos*”. Otra área donde sobresale ML es en problemas que o son muy complejos para el enfoque tradicional, o simplemente hasta ahora no hay un algoritmo conocido.

Aprendizaje.

Según Wikipedia, es el proceso por el cual se adquieren y desarrollan *habilidades, conocimiento, conductas y valores*.

Habilidades son un conjunto de capacidades, destrezas y talentos de un humano o un animal para realizar ciertas acciones.

Conocimiento, hace referencia a la comprensión teórica o práctica de un tema; se adquiere a través del estudio o la experiencia. Puede ser implícito como las habilidades

de un humano o un animal; o explícito como el conocimiento humano escrito. El paso del conocimiento humano de implícito a explícito es complejo y no logra reflejarse completamente.

Conducta, o comportamiento, es el conjunto de reglas que utilizan los seres vivos en su entorno ante la presencia o ausencia de estímulos.

Valores, son cualidades de un objeto, son agregados a las características físicas del objeto.

Entonces el aprendizaje en ML se basa en el principio de que el dataset, el gran conjunto de datos, guarda conocimiento alrededor de un tema específico, en otras palabras, guarda conocimiento que a través de sus técnicas se vuelve conocimiento tácito. Pero es posible que ese dataset no incluya todo el conocimiento necesario para que el modelo que se construya con él no sea el más apropiado para hacer predicciones o clasificaciones.

En resumen, ML es ideal para:

- Solucionar problemas para los cuales existen soluciones que requieren mucho refinamiento o largas listas de reglas: un algoritmo ML generalmente puede simplificar el código y comportarse mejor que el enfoque tradicional de programación.
- Solucionar problemas complejos: para los cuales se usan fundamentos de enfoques tradicionales que no son una buena solución.
- Ambientes fluctuantes: un sistema ML puede adaptarse a nuevos datos.
- Sacar ideas sobre problemas complejos con gran cantidad de datos.

6.5 Aplicaciones de ML

Son muchas las áreas de aplicación de ML, que dejan abierta a muchos nuevos desarrollos en diferentes campos, tanto para la predicción o regresión, como para clasificación:

1. **Traductores automáticos de lenguajes.** Son muy utilizados en diferentes tipos de aplicaciones, pues son universales ya que permiten la traducción de un texto en un lenguaje a otro de más de 50 posibles lenguajes con una muy alta precisión. Esta es una aplicación de ML, muy importante porque permite con facilidad la comunicación entre los seres humanos.
2. **Filtros spam para programas malignos (malware).** Como lo vimos en nuestro ejemplo, la llegada de correos mal intencionados, pueden inducir a generarle problemas al usuario, lo mismo puede suceder con cualquier otro tipo de información textual, como puede ser la publicidad engañosa. Además, poder filtrar los programas engañosos o virus, es de mucha utilidad para el usuario normal.
3. **Reconocimiento de voz.** Incluye paso de voz a texto, en robótica para comandos por voz, identificación de voz, análisis de sentimientos, síntesis de voz y otras. Es un componente clave para muchas aplicaciones.
4. **Reconocimiento de imágenes.** Es una de las aplicaciones más comunes de ML, por la cantidad de utilidad que tiene en campos que van desde la robótica, la seguridad hasta los sistemas de recomendación por imágenes.

5. **Recomendación de productos.** O, Sistemas de Recomendación, se usan mucho en comercio electrónico como en Amazon, AliExpress, Netflix. Una vez uno ha seleccionado un producto las redes sociales lo invaden a uno de información referente al producto.
6. **Asistente personal virtual.** Sistemas que ayudan a la toma de decisiones gerenciales leyendo información directamente de las bases de datos empresariales, haciendo promedios y resúmenes para adecuarlas al ambiente. También en herramientas de negociación.
7. **Vehículos autónomos.** Los carros autónomos ya están en prueba en varios lugares del mundo, lo mismo que muchos robots móviles en empresas industriales. También en aviónica, drones, y para exploración espacial, robots que en determinadas circunstancias funcionan de manera autónoma.
8. **Detección en línea de fraudes.** Las transacciones en línea son permanentes y se utilizan en todo el mundo, aquí la utilización de ML hace estas transacciones confiables y seguras.
9. **Predicción del tráfico.** Las vías del mundo están cada vez más congestionadas y los costos en tiempo y dinero de tener personas y mercancías varadas, es muy alto. De manera que cuando se quiere predecir una ruta hay sistemas confiables que lo hacen como “wase”, que funciona en tiempo real, con base en tecnologías y empresas que proveen estos servicios satelitales.
10. **Diagnóstico médico.** ML se comienza a utilizar en diagnóstico médico, especialmente apoyados en tomografías. Ayuda en diagnóstico y hallazgo de tumores de seno y cerebrales. Aquí es importante destacar la riqueza que hay en las historias clínicas, que se tiene de todos los usuarios de los servicios médicos, de cuya riqueza todavía no se tiene conciencia. Es posible que ya haya equipos para este tipo de diagnóstico que directamente incluyan hardware especializado con Deep Learning, para diagnóstico rápido.
11. **Negocios en mercado de valores.** El uso de ML en mercado de valores esta muy extendido. Aquí la variable tiempo es fundamental, en algunos negocios de Fintech.

La lista anterior viene ordenada por la utilización de datos independientes del ambiente hasta de datos muy dependientes del ambiente. Lo que nos lleva a tratar de definir ¿qué es aprendizaje?

6.5 Algoritmos de ML

Hay muchos otros algoritmos de ML, diferentes a las redes neuronales, que se utilizan con bastante frecuencia, dependiendo de la aplicación,. Entre ellos están:

- Regresión lineal
- Regresión logística
- Algoritmo Bayes simple
- Algoritmo Vecinos más cercanos K-nearest o KNN
- Algoritmo SVM (Support Vector Machine)
- Algoritmo Árboles de decisión

Estos algoritmos se presentan en el Apéndice de este capítulo.

6.6 Tipos de aprendizaje en ML

Ya hemos hablado de aprendizaje cuando estudiamos el aprendizaje supervisado para el algoritmo de retropropagación en RNAs. Por el tipo de aprendizaje se permite de cierta manera una clasificación de algoritmos de ML. Hay cuatro categorías importantes de aprendizaje: aprendizaje supervisado, aprendizaje no supervisado, aprendizaje semi-supervisado y aprendizaje reforzado RL.




Figura 6.5. Tipos de aprendizaje.

6.6.1 Aprendizaje supervisado

Como ya se ha visto, en el aprendizaje supervisado el conjunto de entrenamiento con el que se alimenta el algoritmo incluye las soluciones deseadas llamadas rótulos o labels.




Figura 6.6. Un conjunto de entrenamiento rotulado para clasificación de spam.

El modelo se ajusta a los datos de entrenamiento que comprenden las entradas y las salidas. Las técnicas de aprendizaje supervisado se utilizan en:

1. Modelos de clasificación. Reconoce y agrupa ideas, objetos en categorías predefinidas.
Por ejemplo:
Clasificación de correos Spam y Ham
Retención de clientes
Clasificación de imágenes
Reconocimiento de caras
Salud
2. Regresión. Se da cuando se crea una ecuación, usando diferentes valores de entrada con sus pesos específicos determinados por el valor total del impacto en el resultado y los usamos para generar un estimado del valor de salida.

Por ejemplo, las aerolíneas se basan fuertemente en ML para predecir que tanto deberían cobrar por el boleto de avión. Usan varias características, como los días que faltan para el vuelo, el día de la semana, el destino; para usarlos con el fin de predecir el costo del boleto de un vuelo determinado que maximice sus ganancias.

Otra tarea es predecir un valor numérico objetivo, como el precio de un carro. Sí se tiene un conjunto de datos con características como: kilometraje, edad, marca, y otros, llamados predictores, se puede hacer un modelo de regresión para entrenar el sistema. En la figura 6.7, se tiene un modelo de regresión ajustado con el conjunto de entrenamiento, en este caso con solo un atributo (feature), el kilometraje, para predecir el valor de un carro. En general hay varias características de entrada.




Figura 6.7. Un conjunto de entrenamiento rotulado para regresión.

6.6.2 Aprendizaje no supervisado

Como se puede intuir, el aprendizaje no supervisado se realiza con un dataset que no tiene rótulos. Se utiliza cuando se usan algoritmos de ML para analizar y agrupar con base en datasets no rotulados, sin la necesidad de la intervención humana, por ejemplo en:

1. Agrupamiento (clustering), por ejemplo cuando las organizaciones tratan de hacer segmentación de clientes, para hacer mercadeo efectivo. Es realmente crítico que comprendan quienes son sus clientes para que puedan conectar con ellos de la manera más productiva.

En la figura 6.8, se puede apreciar un conjunto de datos sin rótulo.




Figura 6.8. Un conjunto de entrenamiento rotulado para aprendizaje no supervisado.




Figura 6.8. Agrupamiento, resultado de entrenamiento con aprendizaje no supervisado.

2. Otro ejemplo de tarea no supervisada es la detección de anomalías, por ejemplo, detectar transacciones inusuales en tarjetas de crédito para prevenir el fraude; encontrar defectos de fábrica o eliminar valores atípicos en los datasets para alimentar otro algoritmo de ML. En la figura 6.9, se puede observar cómo al llegar una nueva instancia de una transacción comercial, el algoritmo puede detectar si la transacción es válida o se trata de una anomalía, es decir de un fraude.




Figura 6.9. Detección de anomalías.

3. Reducción de la dimensionalidad. Se refiere a técnicas que reducen el número de variables de entrada, cuando en el número de variables de entrada en un dataset es muy alto, es posible que haya algunos parámetros redundantes.

Los algoritmos de visualización son buenos ejemplos de aprendizaje no supervisado. Al alimentarlos con datos complejos y sus rótulos, estos algoritmos obtienen una representación 2D o 3D de sus datos, que se puede plotear fácilmente. Y tratan de preservar la estructura y la manera en que se puede comprender cómo están orientados y organizados los datos y quizá encontrar patrones no sospechados.

6.6.3 Aprendizaje semi-supervisado

El aprendizaje semi-supervisado (SSL) es una técnica de ML, que se presenta cuando hay una pequeña parte de datos rotulados y cantidades de datos no rotulados, para entrenar un modelo predictivo. Su importancia se debe a lo costoso de la rotulación.

Algunos servicios de almacenamiento de fotos, como Google fotos, son buenos ejemplos de este tipo de aprendizaje. Una vez usted descarga las fotos de su familia allí, este reconoce automáticamente la persona que aparece en diferentes fotografías.




Figura 6.10. Aprendizaje semi-supervisado.

También son varios los proyectos de este tipo que han desarrollado varias redes sociales como FaceBook. Un algoritmo bastante popular es representar los datos rotulados y no rotulados en forma de grafo y luego aplicar un algoritmo de propagación de rótulos. Este difunde rotulaciones hechas por un humano a través de toda la red del data set.

6.6.4 Aprendizaje reforzado

En este tipo de aprendizaje, normalmente se tiene un “agente”, es el sistema de aprendizaje, que toma acciones en un ambiente definido. Aquí se entrenan los agentes para seguir una política, es decir efectuar una secuencia de decisiones.

Para el entrenamiento, el agente observa el ambiente, toma decisiones y ejecuta acciones. El agente recibe una retroalimentación en términos de recompensas de retorno dependiendo de si la acción fue exitosa o penalidades, en caso contrario. Debe aprender por sí mismo cuál es la mejor estrategia, la política, para obtener la mayor recompensa. En el tiempo, una política define qué acción debe escoger el agente cuando está en una situación dada.




Figura 6.11. Aprendizaje reforzado.

Al principio, el agente no conoce nada sobre el ambiente, por lo que toma las acciones de forma aleatoria. Si una acción trae una recompensa positiva, el agente deberá aprender a escoger esa acción más frecuentemente, mientras que, si una acción lleva a una penalidad, el agente tenderá a escoger esa acción menos frecuentemente. Así, **el agente aprenderá a escoger las acciones que maximicen la suma de recompensas recibidas**, que se conoce como **retorno**.

Un muy buen ejemplo del mundo real son los carros autónomos, que tiene varios factores: límites de velocidad, colisiones, zonas de conducción y otros.

Hay tres tipos de algoritmos de aprendizaje por refuerzo:

- **Q-Learning**. El más importante, calcula el refuerzo 'por estados y acciones. Se usa cuando hay un número finito de estados y acciones.
- **Iteración de política**. Calcula el refuerzo por estados y acciones siguiendo dos pasos: evalúa la política en un paso, seguido por un paso de mejora en la política. Hay un agente y un dominio de estados y acciones. La tarea es encontrar una política que cause el refuerzo para incrementar cada estado inicial, sin causar el refuerzo de ningún otro estado sucesor para disminuirlo. Se usa cuando hay un número infinito de estados y acciones.
- **Iteración de valor**. Calcula el refuerzo para estados y acciones usando una señal de refuerzo determinada por una función de refuerzo. Se usa cuando conocemos una ecuación de ambiente y se necesita encontrar una función acción-valor que es una Q-

función que nos da el refuerzo para cada estado y acción. Se debe tener información completa sobre la ecuación de transición del ambiente.

Ver ejecución del juego Bong, en un Notebook de Jupyter.

6.7 Los datos

En el capítulo 1, hablamos de la utilización de los datos como una estrategia para realizar IA, lo que se puede observar directamente en ML. Para resaltar la importancia de los datos, vamos a hablar sobre la irrazonable efectividad de los datos.

En un artículo famoso publicado en 2001, de M. Banko y E. Brill de Microsoft, mostraron que algoritmos muy diferentes a ML, incluyendo los más simples, se comportan casi idénticamente bien, alrededor de la solución de un problema complejo una vez se tengan los datos suficientes: eliminar la ambigüedad en los lenguajes naturales. La idea de que los datos son más importantes que los algoritmos para solucionar problemas complejos fue popularizada por P. Norving, en el artículo “La irrazonable efectividad de los datos”.




Figura 6.12. La irrazonable efectividad de los datos.

Con la digitalización, han aparecido muchas fuentes de datos, de las cuales se pueden extraer nuevos patrones y conocimiento, que pueden ser útiles para el desarrollo de nuevas aplicaciones, en diferentes dominios. Para crear modelos efectivos y de calidad de ML, se deben seguir una serie de pasos que garanticen la consistencia del dataset, como es la preparación de los datos.

El procesamiento de datos incluye tanto la preparación de datos como la ingeniería de características. Antes de preparar los datos, es necesario comprender el resultado que se requiere del modelo de ML que se va a entrenar y, por lo tanto, definir los atributos de los datos que lo van a configurar. Con el resultado que se busca, los datos que se van recopilar se identifican fácilmente y, por lo tanto, se definen sus requisitos de calidad y valor. Esta articulación con el problema garantiza que se sigan los pasos correctos en la preparación del dataset.

6.7.1 Preparación de los datos

Los modelos de ML son específicos de su fuente de datos, por lo que la credibilidad de la fuente y la utilidad de los datos recopilados son esenciales. Es posible que un modelo de ML poderoso, pero entrenarlo con datos erróneos, produzca predicciones erróneas.

La preparación de datos minimiza los errores y permite la monitorización de futuros errores. Esto garantizará que el modelo de ML se entrene con los datos correctos y, por lo tanto, que la predicción del modelo resultante sea más precisa. Un análisis exploratorio de los datos proporciona un resumen del dataset y permite realizar los cambios necesarios en el formato. Además, la preparación de datos ayuda a adaptar los datos a los requisitos del modelo de ML.

6.7.2 Recolección de datos

La recolección de datos es la etapa inicial de la preparación de datos e implica la decisión sobre el dataset en función del resultado esperado del modelo de ML que se va a entrenar. En esencia, la recopilación del conjunto de datos correcto garantiza el resultado correcto. La recopilación de datos consiste en la adquisición, el etiquetado, la ampliación, la integración y la agregación de datos.

6.7.2.1 Adquisición de datos.

Implica identificar la fuente de datos, definir la metodología de recopilación y convertir los datos recopilados en formato digital para su cálculo. La fuente de datos puede ser primaria, es decir, se obtiene directamente de las personas, objetos o procesos estudiados. Cuando la fuente es una parte que ya ha recopilado datos previamente; se denomina fuente secundaria. En esta etapa, se utiliza el análisis exploratorio de datos (EDA), técnica que busca comprender las características y atributos de los dataset. La metodología de recopilación de datos varía según el resultado esperado. Las herramientas y técnicas estadísticas se aplican tanto en la recopilación de datos cualitativos como cuantitativos.

6.7.2.2 Etiquetado de datos

Es el proceso que busca colocarle el rótulo correcto a cada conjunto de características de un dataset, para su utilización en aprendizaje supervisado. Cuando faltan esos rótulos, es un proceso necesario, que es bastante costoso pues generalmente incluye trabajo humano. Por ejemplo en agricultura, se debe utilizar para identificación de enfermedades.

6.7.2.3 Aumento de datos

Es una estrategia de preparación de datos que se utiliza para aumentar la diversidad de datos en el entrenamiento de modelos de ML. Implica el desarrollo de nuevos datos de entrenamiento a partir de datos ya existentes. Permite la introducción de datos no observados o la introducción de variables inferidas mediante modelos matemáticos. Es muy provechoso cuando los datos que se entrenan son complejos y el volumen de datos muestreados es pequeño. El aumento de datos soluciona el problema de los datos limitados y el sobreajuste del modelo.

6.7.2.4 Agregación de datos

La agregación de datos es una técnica que permite reducir el volumen de datos mediante la agrupación. Esta agrupación suele ser de un solo atributo. Por ejemplo, si se tiene un conjunto de datos con el atributo tiempo organizado en días a lo largo de una serie temporal determinada, se pueden agregar los datos en grupos mensuales, lo que facilita el manejo del atributo tiempo. Esto

ayuda a reducir la amplitud de un atributo determinado sin pérdidas tangibles durante la manipulación futura de los datos.

6.7.3 Limpieza de los datos

También conocida como depuración de datos, permite detectar y corregir errores e inexactitudes en los datos recopilados. Se espera que los datos sean consistentes con los requisitos de entrada del modelo de ML. Las principales actividades de la limpieza de datos incluyen el ajuste fino de los datos con ruido y la gestión de los datos faltantes. Esto ayuda a garantizar que el dataset recopilado sea completo y que se elimine cualquier error o sesgo. También incluye la detección de valores atípicos dentro del dataset, tanto numéricos como no numéricos.

6.7.3.1 Análisis Exploratorio de Datos

Se basa en la información que se puede obtener de los datos recopilados y, en ocasiones, implica la visualización de datos. Esta visualización permite comprender las propiedades de los datos, como la asimetría y los valores atípicos. Este análisis se realiza principalmente con estadísticas. Las gráficas permiten comprender la distribución del dataset y el resumen estadístico de todos los atributos. El análisis exploratorio de datos (EDA) permite tomar decisiones, como las técnicas de limpieza de datos que se utilizarán, las transformaciones de datos necesarias, si es necesario reducir los datos.

6.7.3.2 Datos faltantes

Si bien es importante verificar durante la recopilación de datos que todos los atributos del dataset tengan un valor real, a veces hay valores faltantes, lo que dificulta su uso. Por ello, se han descrito diferentes técnicas para gestionar los datos faltantes. Las plataformas de manipulación de datos, como Python y R, incorporan algunas librerías que incluyen estas técnicas. La técnica suele variar según el conjunto de datos; por lo tanto, tras la evaluación de los datos en el análisis exploratorio, se puede seleccionar fácilmente la técnica más adecuada para la asignación de datos faltantes.

6.7.3.2.1 Asignación Deductiva

Sigue las reglas básicas de la lógica y, por lo tanto, es la asignación más sencilla, aunque también la que requiere más tiempo. Aun así, sus resultados suelen ser muy precisos. Por ejemplo, si los datos de los estudiantes indican que el número total de estudiantes es 10 y el número total de exámenes es 10, pero hay un examen sin nombre y Juan no tiene calificaciones registradas, la lógica dicta que el examen sin nombre es de Juan.

6.7.3.2.2 Asignación por Media/Mediana/Moda

Utiliza técnicas estadísticas donde se calculan las medidas centrales de tendencia en un atributo determinado y los valores faltantes se reemplazan con la medida de tendencia central calculada, ya sea la media, la moda o la mediana de ese atributo. Se aplica en datasets numéricos y afecta la fuente de datos inicial y el resultado del modelo. Las plataformas de manipulación de datos como Python y R tienen técnicas integradas para tratar datos faltantes.

6.7.3.3 Datos con Ruido.

La presencia de datos con ruido puede tener un efecto sustancial en el resultado de un modelo de ML, afecta negativamente la predicción del modelo. Los datos con ruido incluyen información innecesaria, valores redundantes y valores duplicados o inútiles. Esto se debe a errores en la recopilación de datos, problemas derivados de la entrada de datos, problemas derivados de las

técnicas de transferencia de datos, convenciones de nomenclatura desiguales y a restricciones tecnológicas, en el caso de los datos no estructurados. Los datos con ruido se eliminan mediante: el suavizado del dataset, la regresión lineal y el agrupamiento de datos.

6.7.4 Transformación de los datos.

La transformación de datos implica cambiar los datos depurados de un formato a otro, de una estructura a otra, o modificar los valores del conjunto de datos depurados para cumplir con los requisitos del modelo de aprendizaje automático. La simplicidad de la transformación de datos depende en gran medida de los datos de entrada necesarios y del conjunto de datos disponible. Incluye, la normalización, la selección de atributos, la discretización.

6.7.5 Reducción de los datos

Con el avance de las tendencias en tecnologías de la información y el crecimiento exponencial del IoT, se ha producido un aumento vertiginoso en el volumen de datos disponibles. Si bien, supone una gran ventaja para el ML, ya que la disponibilidad de big data para el entrenamiento de los modelos garantiza la precisión de la información generada por estos, la gestión y el análisis de estos enormes volúmenes de datos supone un gran reto, de ahí la necesidad de técnicas de reducción de datos. La reducción de datos reduce los costos de analizar y almacenar volúmenes de datos al aumentar la eficiencia del almacenamiento. Entre las técnicas se incluyen: el uso de cubos de datos y la selección de las características.

6.7.6 Sesgos en la preparación de los datos

El sesgo en los datos que entrenan en el modelo de ML hace predicciones erróneas. Es fundamental identificar en la fuente cualquier sesgo en el dataset durante la preparación y eliminarlo. El sesgo de muestra se produce durante la recopilación de datos, cuando la muestra seleccionada no representa correctamente a la población en estudio. Por ejemplo, un sistema de reconocimiento de iris entrenado exclusivamente con iris de personas africanas no identificará eficazmente los ojos de la población blanca.

El sesgo de exclusión es común en la etapa de limpieza de datos, donde se elimina o se tergiversa una parte de los datos, lo que lleva a su exclusión del entrenamiento del modelo. El sesgo de medición se produce durante el etiquetado de datos, donde un etiquetado no uniforme da lugar a predicciones erróneas del modelo de aprendizaje automático. El sesgo de recuperación también se produce en la etapa de etiquetado de datos, cuando el etiquetado no es consistente.

Otro es el sesgo racial, y el mejor ejemplo de este sesgo en los motores de búsqueda de voz, donde el modelo se entrenó principalmente con datos de voz de la población blanca y, por lo tanto, apenas reconoce la voz de la población negra [19]. El sesgo de asociación ocurre cuando un conjunto de datos ha creado una asociación implícita entre atributos. El principal sesgo de asociación es el sesgo de género, como en el caso en que un sistema se entrena con todos los directores de escuela hombres, lo que finalmente descalifica la plausibilidad de una directora de escuela.

6.8 Data sets en ML

Un data set es una colección de datos utilizada para crear, probar, afinar y en general trabajar modelos de ML. Cada elemento o registro de un data set, actúa como un ejemplo para

enseñarle al algoritmo de ML cómo debe predecir un resultado cuando en producción se le entra un punto de datos. Los propósitos básicos de un data set son para entrenar un modelo y para medir su precisión cuando ya está entrenado. A este data set se le conoce como benchmark.

6.8.1 Partición del Data set en ML

En el momento de entrenamiento de los modelos, el dataset generalmente se particiona en tres conjuntos: el conjunto de entrenamiento, el conjunto de prueba y el conjunto de validación.

Conjunto de entrenamiento. Es el más importante y se compone de alrededor del 60% del dataset. Comprende los datos que serán utilizados para entrenar el modelo, en otras palabras le indica al algoritmo lo que debe buscar en los datos.

Conjunto de validación. Se usa para comprender el comportamiento de un modelo determinado a través de diferentes tipos de modelos. Permite darle validez al modelo en estudio. Cuando la precisión del conjunto de validación es mayor que la precisión obtenida con el conjunto de entrenamiento, estamos hablando de que el modelo está sobre-entrenado.

Conjunto de prueba. Se usa para aproximar la precisión imparcial del modelo y darle una evaluación objetiva. Se busca un conjunto de datos del mundo real que todavía el modelo no conoce.

6.8.2 Data set abiertos

Son data sets listos para utilizar, que están disponibles, gratis, para descargar, utilizar, modificar y distribuir, sin restricciones legales o financieras. Para tipos de datos más específicos, ver <https://research.aimultiple.com/datasets-for-ml/>

Data sets abiertos públicos

Son conjuntos de datos de proyectos gubernamentales, disponibles al público. Pueden incluir censos, datos demográficos y otros. En Colombia, [la Ley 1712 de 2014 de la Ley de Transparencia y del Derecho de Acceso a la Información Pública Nacional](#), establece la obligatoriedad de las entidades públicas de aperturar datos y define los datos abiertos en el numeral sexto como *"todos aquellos datos primarios o sin procesar, que se encuentran en formatos estándar e interoperables que facilitan su acceso y reutilización, los cuales están bajo la custodia de las entidades públicas o privadas que cumplen con funciones públicas y que son puestos a disposición de cualquier ciudadano, de forma libre y sin restricciones, con el fin de que terceros puedan reutilizarlos y crear servicios derivados de los mismos"*.

6.9 Lenguajes y librerías

Para el desarrollo de aplicaciones ML, es preciso tener conocimientos de programación, de estructuras de datos, de manejo de memoria y mínimo de un lenguaje de programación. Además, hay muchas librerías que se ofrecen para diferentes lenguajes de programación para hacer ML, por lo que es muy fácil para personas con los conocimientos básicos señalados.

Por otra parte, en concepto de otros expertos, no hay un mejor lenguaje para ML, cada uno es bueno en determinado campo. Por ejemplo, la mayoría de los ingenieros de ML prefieren usar Python para problemas de lenguaje natural NLP, mientras que para análisis de sentimientos prefieren usar Python o R, y algunos probablemente van a usar Java, para otras aplicaciones de ML como seguridad y detección de amenazas.

Python

En estos momentos hay más de 8 millones de desarrolladores alrededor del mundo que usan Python. Según Spectrum de la IEEE, es el primer lenguaje utilizado, en este último año. Pero hay más: es fácil de aprender, hay una comunidad madura que brinda soporte y en mi concepto lo más importante, hay cientos de librerías que permiten desarrollos rápidos en muchos temas de IA.




Figura 6.13. Uso de lenguajes de programación. Fuente Stack Overflow

R

Con más de dos millones de usuarios, 12000 paquetes en el repositorio CRAN, aproximadamente 206 grupos Meetup, más de 4000 preguntas sobre programación R cada mes, R es un lenguaje para escribir ML de estadísticas para estadísticos.

6.10. Proyectos de ML

Para el desarrollo de un proyecto de ML, se deben considerar los siguientes pasos:

1. Definir el objetivo del proyecto
2. Definir las características, o features, o variables del proyecto
2. Definir el criterio de evaluación
3. Evaluar la solución actual
4. Obtener un data set confiable y con los datos suficientes
5. Seleccionar el modelo
6. Analizar los errores del modelo

7. Aplicar el modelo para el objetivo planteado




Figura 6.14, modelo para la implementación de sistemas de ML

6.11. ML oscura

Ahora más que nunca, los avances tecnológicos en ML nos traen soluciones revolucionarias a muchos problemas. Con todo lo positivo de estos desarrollos, también es necesario tener en cuenta los matices de estos avances que a veces hacen daño, en lugar de ayudar.

Un modelo de ML con sesgo, comienza a presentar resultados con prejuicios sistémicos como sesgos demográficos, culturales y estéticos. Bajo el paraguas de la IA y el ML, se utilizan datasets de entrenamiento para “enseñarle” a las máquinas sus funciones predictivas. Finalmente, la raíz de este problema es un error humano; los data sets incompletos llevan a predicciones imprecisas. Sin un amplio rango de representación de los diversos grupos en el mundo que utilizan internet, los productos digitales están sujetos a reflejar sesgos cognitivos no deseados, que señalan culturas, identidades, ..., específicas únicas.

Veamos un caso en Amazon, con experiencia en IA, donde ha habido problemas. Según un reporte de Reuters, este gigante del e-commerce tenía un sistema interno que usaba IA para examinar las aplicaciones, que hacen las personas interesadas en trabajar con Amazon. Después de algunas quejas se encontró que una herramienta de reclutamiento de personal tenía perjuicios contra las mujeres degradándolas consistentemente. Este sistema fue descartado por Amazon, luego de observarse estos comportamientos.

Como se ha visto, los sistemas de ML funcionan con datos históricos, en los que se han mantenido estos prejuicios, generalmente llevando a que se perpetúen los prejuicios existentes. En este caso el prejuicio estaba en los ambientes de trabajo dominados por hombres.

Otra manera en que se implementan prejuicios de género y raza se debe a cómo, de manera inconsciente, los desarrolladores hacen las implementaciones con estos sesgos. Este es un problema muy complicado de resolver y la única solución es a través de una muy buena educación, consideración que las empresas de desarrollo en general no son conscientes.

En su libro, Cathy O'Neal, "Armas Matemáticas de Destrucción", plantea que estamos viviendo en la edad del algoritmo, que las decisiones que afectan nuestras vidas no las toman los humanos sino los modelos matemáticos. En teoría esto lleva a una mayor equidad, pues en principio, todos somos juzgados por las mismas reglas. Pero en la práctica ocurre todo lo contrario, los modelos son opacos, no están regulados, son incontestables. Esto lleva a un refuerzo en la discriminación.

Supongamos que ustedes se gradúan, generalmente van a trabajar en el desarrollo de un proyecto. En poco tiempo ven la necesidad de salir de la casa y adquirir un apartamento pequeño. Van al banco donde le consignan su salario y manifiestan su interés de compra con el fin de conocer todas las condiciones para que le presten para una hipoteca. Y comienzan los problemas, si bien su ingreso es alto, no tiene contrato a término indefinido, no tiene experiencia crediticia y otros. Las reglas de la banca actual no permiten que se le otorgue un préstamo, estas reglas se llevan a los algoritmos, perpetuando la discriminación.

En el libro "THE BOOK OF WHY", J. Pearl y D. Mackenzie, plantean el problema de ML en el sentido que llevan a que características (features) altamente correlacionados se asumen como relaciones causa efecto, llevando a veces a resultados completamente desatinados. Sin embargo, es importante destacar el problema de que la correlación no implica causa.

Por ejemplo, si se hiciera una gráfica de atracos en Colombia contra el número de ingenieros mecánicos, se tendría una correlación espuria y se construyera un modelo entrenado con un dataset de este tipo, simplemente no funcionaría ya que el modelo no entiende las causas detrás de las relaciones entre los datos, por lo que se hace necesario que entendamos la pregunta del porqué de estas relaciones. Y es aquí donde nace una ciencia poco conocida, aunque también cada vez más en auge, como es la **inferencia causal**.

La inferencia causal consiste en el proceso de identificar y entender las relaciones causa-efecto entre variables. En muchas áreas de investigación, incluyendo la epidemiología, la economía, la ciencia política y la psicología, la inferencia causal es crucial para entender los efectos de las intervenciones, políticas o programas. La inferencia causal también ayuda a predecir el resultado de cambios en las variables, lo que puede ser especialmente útil en el diseño de experimentos y en la toma de decisiones. De manera que en modelos de ML se debe considerar hacer este tipo de análisis para darles una mayor validez.

6.12. Ejercicios

1. Considere la figura 6.1. Conforme un data set con resultados de 50.000 multiplicaciones de matrices 2×2 , generadas aleatoriamente con números enteros entre -20 y 20. Una vez entrenado el modelo, úselo con 10 ejemplos y compare los resultados con los que se producen al realizar la operación analíticamente. Haga un cálculo de que es más costoso computacionalmente.

En alguno de los siguientes problemas, usar datos de alguna entidad gubernamental.

2. Estudie el algoritmo SVM con todo detalle, mejore su documentación y con base en el haga cambios para una aplicación.

3. Estudie el algoritmo de K-Nearest, con todo detalle mejore su documentación y con base en el haga cambios para una aplicación.

4. Estudie el algoritmo de árboles de decisión, con todo detalle mejore su documentación y con base en el haga cambios para una aplicación.

5. Estudie el algoritmo de Bayes ingenuo y haga un ejemplo bien documentado.

De los últimos 4 ejercicios haga 3.

Nuevamente, si tiene otro problema que le parezca interesante en el que se use ML, lo puede cambiar, por uno de los ejercicios planteados.

6.13 Bibliografía

Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, Concepts, Tools, and Techniques to Build Intelligent Systems, **Aurélien Géron**.

Machine Learning in Robotics, 5 Modern Applications, Daniel Fegguella, <https://emerj.com/ai-sector-overviews/machine-learning-in-robotics/>

Cathy O'Neal, Armas Matemáticas de Destrucción, 1972

J. Pearl y D. Mackenzie, THE BOOK OF WHY, The New Science of Cause and Effect, Basic Books, 2018.

Laurence Moroney, AI and Machine Learning for Coders, O'Reilly Media, 2020

Data preparation for ML, Rachael Njeri Ndung'u, Murang'a University College, 2020